NovaRetail 360

Perfilamiento y limpieza con Power Query, modelo relacional y SQL para inteligencia de negocios

Taller 1 – Laboratorio de guía

Asignatura: Inteligencia de Negocios
Docente: Nancy Yaneth Gelvez Garcia
Estudiantes: Juan Felipe Rodríguez Galindo – 20261595004
Programa: Maestría en Ciencias de la Información y las Comunicaciones
Fecha: 8 de octubre de 2026

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería – Bogotá D.C., Colombia

Índice

1. Resumen ejecutivo **2**

2. Datos y método **2**

3. Parte A – Perfilamiento y limpieza **3**

3.1. Importación y diagnóstico . . . 3
3.2. Bitácora de calidad . . . 3
3.3. Normalización y tipificación . . . 3
3.4. Auditoría de registros . . . 4
3.5. Variables calculadas y política de devoluciones . . . 4
3.6. Conciliación: el total casi no cambia, la composición sí . . . 5
3.7. Reproducibilidad . . . 5

4. Parte B – Modelo relacional **5**

4.1. Diagrama entidad–relación . . . 6
4.2. Granularidad de `ventas` y de `metas` . . . 6
4.3. Operacional frente a estrella . . . 7

5. Parte C – Consultas SQL **7**

5.1. Consultas de la guía . . . 7
5.2. LEFT JOIN, INNER JOIN y calidad de datos . . . 10
5.3. `WHERE` frente a `HAVING`; `COUNT(*)` frente a `COUNT(DISTINCT)` . . . 11
5.4. Verificación cruzada . . . 11

6. Parte D – Indicadores y recomendación ejecutiva **11**

6.1. Tres indicadores . . . 11
6.2. Recomendación ejecutiva . . . 11
6.3. Limitaciones . . . 12

7. Reproducir el trabajo **12**

A. Consultas SQL comentadas **12**

1. Resumen ejecutivo

NovaRetail 360 es un caso ficticio de comercio minorista con seis meses de ventas (enero a junio de 2026). La gerencia necesita ventas netas, devoluciones, mezcla de canales, cumplimiento de metas y comportamiento regional, pero los archivos recibidos traen errores de calidad. Este informe documenta cómo se depuraron los datos, cómo se modeló la información y qué dicen los números una vez depurados.

- **Calidad.** De 1 201 filas de ventas se aceptaron 1 194. Se corrigieron 5 por reglas deterministas o con evidencia, se apartaron 7 a una tabla de auditoría (ninguna se borró) y se registraron 12 incidencias con regla, evidencia, impacto y decisión.
- **Ventas netas.** $ 700,0 millones, $ 737,6 millones brutos; el descuento promedio efectivo es 5,09 %.
- **Metas. Ninguna** de las 30 combinaciones mes–región alcanza su meta; el cumplimiento global es 40,8 %, y varía muy poco entre regiones (38,9 % a 41,8 %).
- **Devoluciones.** 4,15 % de las unidades (4,28 % del valor); Tecnología concentra el problema con 6,10 %.
- **Canales.** Web, Marketplace y Tienda pesan prácticamente lo mismo (33,5 %, 33,5 % y 33,0 %).

Recomendación. Antes de juzgar a las regiones, validar con el negocio cómo se definió la meta: un cumplimiento uniforme cercano a 40 % en todas partes apunta a un problema de escala o de definición de la meta más que a un problema comercial regional. En paralelo, revisar la calidad y el empaque de la categoría Tecnología. Las limitaciones (datos sintéticos, seis meses, sin costos) se detallan en la sección 6.

Qué se entrega y qué no. Se entrega el pipeline reproducible (Python y SQLite), las consultas M de Power Query equivalentes, la base `novaretail.db`, la bitácora, el diagrama entidad–relación y las consultas SQL. **No se entrega un archivo `.pbix`**: el trabajo se hizo en macOS, donde Power BI Desktop no existe, y los guiones M no se ejecutaron en Power BI. La guía admite en ese caso evidencias de las transformaciones y los datos depurados, que es lo que se aporta.

2. Datos y método

Tabla 1: Archivos recibidos.

Archivo	Filas	Contenido
`ventas_sucias.csv`	1 201	Transacciones: fecha, cliente, producto, canal, cantidad, precio, descuento
`clientes.csv`	120	Maestro con región (5) y segmento (Persona/Corporativo)
`productos.csv`	40	Catálogo con categoría (4) y precio de lista
`devoluciones.csv`	70	Unidades devueltas por venta, con motivo (Defecto/Cambio)
`metas.csv`	30	Meta de ventas por mes y región (6 meses $\times$ 5 regiones)

El flujo es el mismo en todo el trabajo: se perfilan los datos, se aplican reglas explícitas, se separa lo rechazado en lugar de borrarlo y se verifica que *aceptadas* + *rechazadas* = *crudas* ($1\,194 + 7 = 1\,201$).

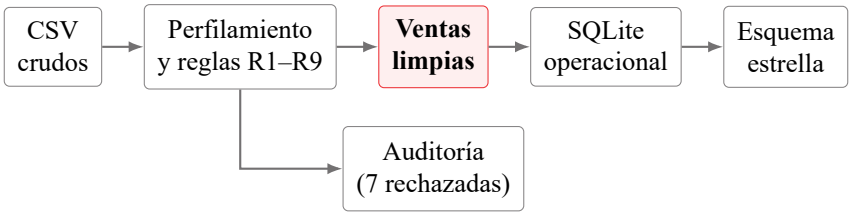


Figura 1: Flujo de depuración y carga.

3. Parte A -- Perfilamiento y limpieza

3.1. Importación y diagnóstico

Se importaron los cinco archivos y se revisaron tipos, nulos, duplicados, valores inválidos y referencias a claves inexistentes. Cuatro archivos salieron limpios (clientes, productos, devoluciones y metas: claves únicas, sin nulos, 30 metas sin huecos y las 70 devoluciones con venta y cantidad devuelta menor o igual a la vendida). Todas las incidencias están en `ventas_sucias.csv`.

3.2. Bitácora de calidad

Tabla 2: Bitácora de calidad: una fila por incidencia (detalle y evidencia en `salida/bitacora_calidad.csv`).

#	Venta	Regla	Valor observado	Decisión	Acción
1	V00016	R2 formato fecha	`15/02/2026`	Convertir a `2026-02-15`; día >12 solo admite dd/mm	Corregida
2	V00039	R2 fecha obligatoria	vacío	Rechazar; no se inventa una fecha	Auditoría
3	V00054	R3 cliente	`C9999`	Rechazar; clave inexistente en el maestro	Auditoría
4	V00073	R3 producto	`P999`	Rechazar; clave inexistente en el catálogo	Auditoría
5	V00093	R4 cantidad > 0	-2	Rechazar; podría ser una devolución mal registrada	Auditoría
6	V00116	R4 cantidad > 0	vacío	Rechazar; no hay fuente para recuperarla	Auditoría
7	V00141	R6 precio > 0	vacío	Imputar `precio_lista` (179 400; importe 358 800)	Corregida
8	V00167	R5 descuento	1,25	Rechazar; recortar sería arbitrario	Auditoría
9	V00186	R7 canal	`'web '`	Normalizar a `Web` (trim + proper case)	Corregida
10	V00213	R7 canal	`WEB`	Normalizar a `Web`	Corregida
11	V00240	R1 unicidad	fila repetida	Conservar la primera, auditar la segunda	Auditoría
12	V00410	R6 precio > 0	$-20\,000$	Imputar `precio_lista` (289 600; importe 579 200)	Corregida

3.3. Normalización y tipificación

- **Canal.** Se recortan espacios y se unifica la capitalización. Sin esto aparecerían cinco canales (`Web`, `web␣`, `WEB`, …) y se partiría la participación.
- **Fechas.** Se convierten a ISO (`aaaa-mm-dd`). Una sola fecha viene en `dd/mm/aaaa` y se resuelve sin ambigüedad porque el día (15) es mayor que 12. En Power Query la conversión debe indicar la cultura explícitamente (`es-CO`); si se deja la del equipo, un mismo archivo da resultados distintos en máquinas distintas.
- **Cantidades, precios y descuentos.** Enteros positivos para cantidad y precio; descuento dentro de la escala

comercial observada (0, 0,05, 0,10 y 0,15). Los números del CSV usan punto decimal, así que se leen con cultura `en-US`.

Precio faltante: por qué se imputa y la cantidad no. En 1 198 de 1 198 ventas con precio válido y producto existente, el precio unitario coincide exactamente con el `precio_lista` del catálogo. Hay evidencia suficiente para recuperar un precio faltante o negativo desde el catálogo (reglas R6). No hay nada equivalente para cantidad o descuento, así que esos registros se rechazan.

3.4. Auditoría de registros

Los siete registros rechazados se conservan en `auditoria_rechazados.csv` (y en la tabla `auditoria_rechazados` de la base) con su motivo. Ninguna devolución apunta a una venta rechazada.

Tabla 3: Registros rechazados por motivo.

Motivo	Registros
R4 cantidad inválida (V00093, V00116)	2
R1 venta repetida (V00240)	1
R2 fecha vacía (V00039)	1
R3 `id_cliente` inexistente (V00054)	1
R3 `id_producto` inexistente (V00073)	1
R5 descuento fuera de rango (V00167)	1
Total	**7**

3.5. Variables calculadas y política de devoluciones

$$\text{importe_bruto} = \text{cantidad} \times \text{precio_unitario}$$
$$\text{importe_neto} = \text{importe_bruto} \times (1 - \text{descuento})$$

Política de devoluciones. (1) Las devoluciones *no se restan* del importe neto de la venta: `importe_neto` sigue siendo lo facturado. (2) Cada devolución se vincula a su **venta original** y su valor es unidades devueltas $\times$ precio $\times$ $(1 - \text{descuento})$ de esa venta; así no se suman importes dos veces. (3) La tasa de devolución se mide **en unidades** (unidades devueltas / unidades vendidas), no en transacciones, porque una venta de seis unidades con una devuelta no es una transacción perdida. (4) El valor devuelto se reporta aparte (4,28 % de las ventas netas) para quien necesite una cifra neta de devoluciones ($ 670,0 millones).

3.6. Conciliación: el total casi no cambia, la composición sí

Tabla 4: Puente de conciliación entre la lectura ingenua del archivo y el conjunto depurado (pesos).

Concepto	Importe neto
Suma ingenua del archivo (blancos = 0, sin validar)	701 679 450
Quitar venta repetida V00240	−1 015 920
Quitar cliente inexistente V00054	−1 476 960
Quitar producto inexistente V00073	−547 200
Quitar fecha vacía V00039	−168 030
Quitar cantidad negativa V00093 (restaba)	+326 800
Quitar descuento 125 % V00167 (restaba)	+225 000
Imputar precio faltante V00141 (valía 0)	+358 800
Imputar precio negativo V00410 (restaba)	+619 200
Conjunto depurado	**700 001 140**

La diferencia total es de solo 0,24 %, porque unos errores suman y otros restan. Por eso no sirve validar un archivo mirando su total: los errores quedan escondidos hasta que se mira la composición por región, canal o mes.

3.7. Reproducibilidad

Cómo la garantizan los pasos aplicados. Power Query guarda cada transformación como una línea de código M dentro de la consulta (*Applied Steps*). Al llegar un archivo nuevo basta actualizar: se repiten todos los pasos, en el mismo orden, con las mismas reglas. Esa receta se puede leer, versionar y revisar. En este trabajo la misma lógica está en `power_query/*.pq` y en `pipeline/limpieza.py`, y las dos producen la partición aceptadas/rechazadas.

Riesgos de reemplazar valores sin una regla documentada.

- *Sesgo silencioso*: reemplazar vacíos por 0 baja promedios y ventas; reemplazar 1,25 por 0,15 inventa un descuento que nadie aprobó.
- *Sin trazabilidad*: el valor original se pierde y nadie puede revisar la decisión.
- *Fragilidad*: un reemplazo de un valor literal (“C9999” por “C0001”) no se aplica a la siguiente entrega, que traerá otros valores sucios, y el proceso falla o, peor, pasa en silencio.
- *Dependencia del orden*: cambiar tipos antes de normalizar texto puede producir errores que luego se ocultan con *Reemplazar errores*.

La alternativa que se adoptó: reglas expresadas como condiciones (no como valores), conservación del registro original y una consulta de auditoría complementaria.

4. Parte B -- Modelo relacional

4.1. Diagrama entidad--relación

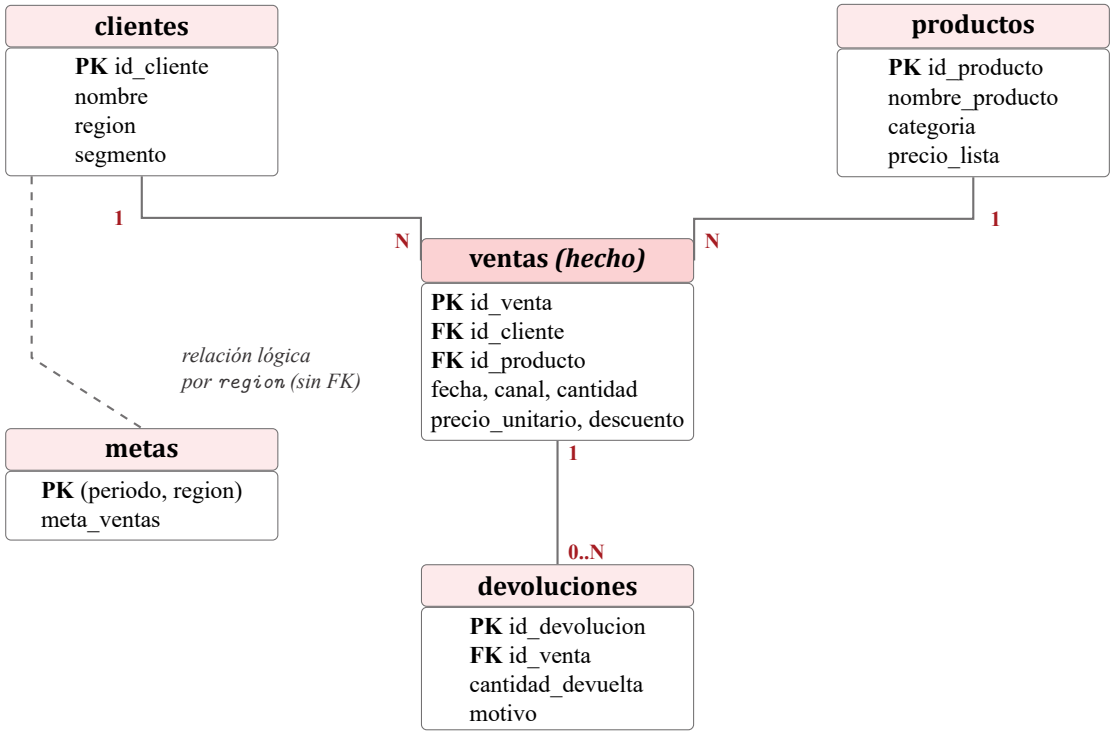


Figura 2: Modelo operacional. Las líneas continuas son claves foráneas; la línea punteada, una relación lógica por atributo entre `metas` y la región del cliente.

Tabla 5: Claves y cardinalidades.

Relación	Cardinalidad	Lectura
clientes → ventas	1 : N	Un cliente tiene muchas ventas; toda venta pertenece a un cliente existente
productos → ventas	1 : N	Un producto aparece en muchas ventas; toda venta tiene un producto del catálogo
ventas → devoluciones	1 : 0..N	Una venta puede tener cero, una o varias devoluciones (en los datos, 70 ventas con una)
metas ↔ clientes	N : M lógica	La meta se define por (mes, región); la región es atributo de cliente, no entidad

La región no tiene tabla propia. Una mejora sencilla del modelo operacional es extraerla a `regiones` y que tanto `clientes` como `metas` la referencien; así la relación punteada se vuelve una clave foránea real.

4.2. Granularidad de `ventas` y de `metas`

Ventas: una fila por transacción (`id_venta`), con un producto por transacción. Es el grano más fino disponible: de él se puede subir a cualquier agregado (día, región, canal, categoría), pero no al revés.

Metas: una fila por mes y región. Si se une `metas` directamente a cada transacción, el valor de la meta se repite en cada venta de su mes y región: en promedio 39,8 veces. Al sumar la meta sobre ese resultado, el total deja de ser $ 1 715 millones y pasa a $ 68 377 millones, es decir 39,9 veces más (se verificó en la base). El mismo error afecta a cualquier unión entre tablas de granularidad distinta: se llama *fan-out*. La regla es agregar las ventas al grano de la meta (mes, región) *antes* de unir.

4.3. Operacional frente a estrella

Tabla 6: Comparación de los dos modelos.

Aspecto	Operacional normalizado	Esquema estrella
Objetivo	Capturar transacciones sin redundancia ni anomalías	Responder preguntas analíticas con pocas uniones
Estructura	5 tablas en 3FN, uniones por FK	3 hechos (ventas, devoluciones, metas) y 4 dimensiones (fecha, cliente, producto, canal)
Consultas típicas	Varias uniones; el analista debe conocer el modelo	Hecho + dimensiones; atributos listos para filtrar (región, mes, categoría)
Escritura	Eficiente y consistente	Se carga por lotes; admite redundancia en dimensiones
Metas	Se unen con cuidado (distinto grano)	Hecho propio al grano mes–región; se compara por dimensiones conformadas (región, mes)
Riesgo	Fan-out por olvidar el grano	Dimensiones mal conformadas

El esquema estrella está implementado en la base (`sql/10_estrella.sql`). Se verificó que `fact_ventas` suma exactamente lo mismo que `ventas` (diferencia 0).

5. Parte C -- Consultas SQL

Las consultas completas y comentadas están en el anexo y en `sql/20_consultas.sql`. Los resultados vienen de la base SQLite construida por el equipo con los datos depurados.

5.1. Consultas de la guía

Q1. Ventas netas por región y mes. Se une `ventas` con `clientes` para obtener la región.

Tabla 7: Q1: ventas netas por región y mes (millones de pesos).

Región	Ene	Feb	Mar	Abr	May	Jun	Total
Bogotá	14,2	23,0	29,4	26,3	20,7	17,6	131,2
Medellín	20,9	16,6	24,0	31,5	16,4	28,2	137,6
Cali	27,3	23,5	30,6	21,8	20,5	24,2	147,9
Barranquilla	22,1	24,3	19,7	22,4	27,9	24,0	140,5
Bucaramanga	29,1	22,8	22,2	23,6	18,1	27,1	142,8
Total	113,6	110,3	125,9	125,5	103,6	121,2	**700,0**

Acumulado por región frente a la meta (insumo del indicador I1):

Tabla 8: Ventas netas por región, enero–junio 2026 (millones de pesos).

Región	Ventas netas	Meta	Cumplimiento
Bucaramanga	142,8	342,0	41,8 %
Cali	147,9	355,0	41,7 %
Bogotá	131,2	317,0	41,4 %
Medellín	137,6	340,0	40,5 %
Barranquilla	140,5	361,0	38,9 %
Total	**700,0**	**1 715,0**	**40,8 %**

Q2. Cinco productos con mayores ingresos. Se agrupa por `id_producto` (no por nombre).

Tabla 9: Top 5 de productos por ingreso neto.

Producto	Nombre	Categoría	Unidades	Ingreso (millones)
P037	Producto 037	Hogar	160	44,8
P035	Producto 035	Accesorios	136	36,6
P039	Producto 039	Accesorios	110	32,8
P040	Producto 040	Tecnología	109	32,8
P038	Producto 038	Oficina	113	32,3

Q3. Participación por canal.

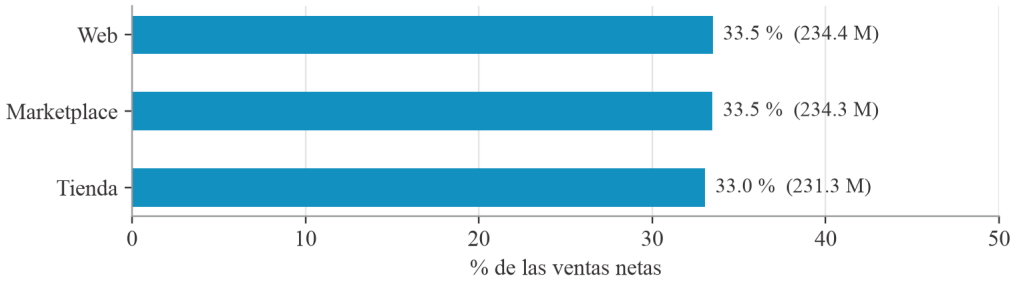


Figura 3: Participación por canal en las ventas netas.

Q4. Tasa de devoluciones por unidades. Se calcula con dos agregaciones independientes que luego se dividen: 174 unidades devueltas sobre 4 196 vendidas, **4,15 %**. Si se uniera `devoluciones` a `ventas` y se sumara `cantidad`, una venta con varias devoluciones repetiría sus unidades vendidas. En estos datos cada venta tiene como máximo una devolución, así que el riesgo no se materializa, pero la consulta se escribió para no depender de eso.

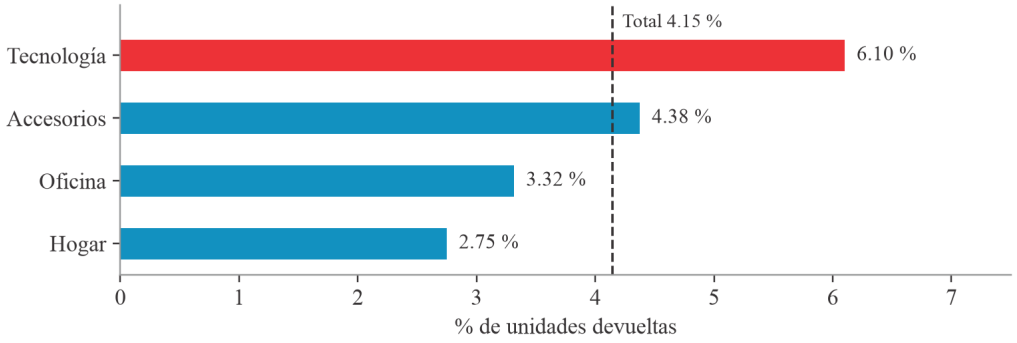


Figura 4: Tasa de devolución en unidades por categoría.

Q5. Cumplimiento de metas por mes y región. Las ventas se agregan a (mes, región) antes de unir con `metas` mediante `LEFT JOIN` desde `metas`, así una combinación sin ventas aparece con 0 % en vez de desaparecer.

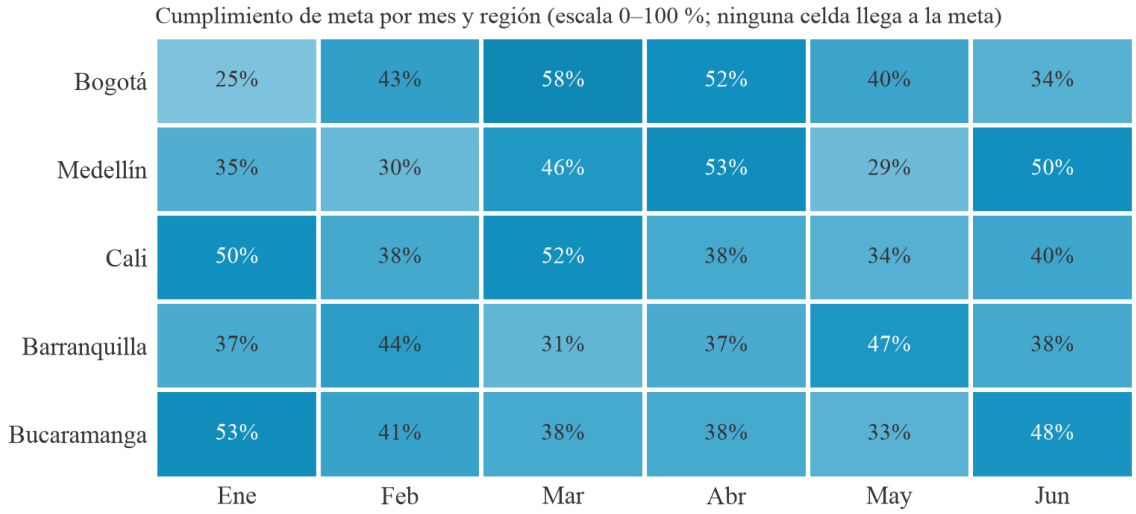


Figura 5: Cumplimiento de meta. El rango observado es 24,9 % (Bogotá, enero) a 57,6 % (Bogotá, marzo).

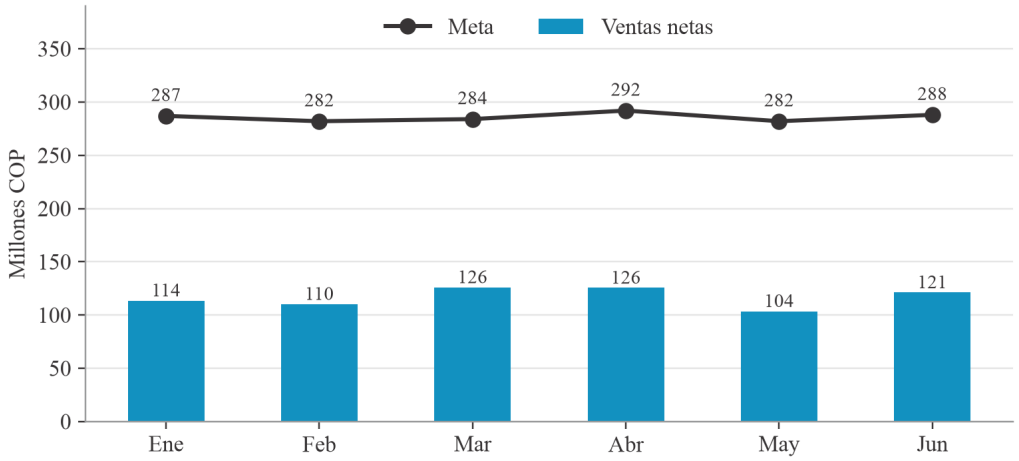


Figura 6: Ventas netas frente a meta por mes, todas las regiones (millones de pesos).

5.2. LEFT JOIN, INNER JOIN y calidad de datos

Sobre los datos *crudos*, un `LEFT JOIN` desde `ventas_crudas` hacia `clientes` y `productos`, filtrando donde la clave del lado derecho es nula, devuelve exactamente las dos ventas huérfanas (V00054 con cliente `C9999` y V00073 con producto `P999`). El mismo cruce con `INNER JOIN` devuelve 1 199 filas de 1 201: las dos desaparecen sin mensaje de error ni advertencia, y los totales salen "bien" porque nadie ve lo que falta. Por eso el `LEFT JOIN` con prueba de nulos es la herramienta de auditoría, y el `INNER JOIN` solo se usa cuando la integridad ya está garantizada (o cuando descartar es la decisión deliberada).

5.3. `WHERE` frente a `HAVING`; `COUNT(*)` frente a `COUNT(DISTINCT)`

- `WHERE` filtra *filas* antes de agrupar; no puede usar funciones de agregación. `HAVING` filtra *grupos* después de agregar. Ejemplo (`sql/30_calidad_y_conceptos.sql`): con `WHERE fecha >= '2026-03-01'` se descartan las ventas de enero y febrero antes de sumar; con `HAVING SUM(importe_neto) >` 95 000 000 solo sobreviven las regiones cuyo total ya agregado supera ese valor (Medellín y Cali).
- `COUNT(*)` cuenta filas; `COUNT(DISTINCT id_venta)` cuenta ventas únicas. Sobre las ventas crudas da 1 201 frente a 1 200: la diferencia es exactamente el duplicado V00240. Tras unir con una tabla de relación 1:N (por ejemplo devoluciones múltiples) `COUNT(*)` sobrecontaría ventas, mientras que `COUNT(DISTINCT id_venta)` no.

5.4. Verificación cruzada

El archivo `consultas_referencia.sql` que acompaña la guía se ejecutó sobre la base depurada y arroja los mismos números que las consultas propias en ingreso por región y mes y en cumplimiento de metas.

6. Parte D -- Indicadores y recomendación ejecutiva

6.1. Tres indicadores

Tabla 10: Indicadores empresariales.

Indicador	Valor	Lectura
I1. Cumplimiento de metas (ventas netas / meta)	40,8 % (0 de 30 cumplen)	Uniforme entre regiones (38,9 % a 41,8 %); no hay una región “problema”.
I2. Tasa de devolución en unidades	4,15 % (valor: 4,28 %)	Tecnología 6,10 %, Accesorios 4,38 %, Oficina 3,32 %, Hogar 2,75 %. Por región, de 2,43 % (Bucaramanga) a 4,90 % (Cali).
I3. Mezcla de canales (participación en ventas netas)	33,5 % / 33,5 % / 33,0 %	Sin dependencia de un canal; ningún canal es la palanca obvia de crecimiento.

Otros datos de contexto: ticket promedio de $ 586 266 por transacción, 120 de 120 clientes activos, 55 % de las ventas en el segmento Corporativo (que es la mitad de los clientes), y descuentos por $ 37,6 millones (5,09 % del bruto).

6.2. Recomendación ejecutiva

1. **Revisar la definición de las metas antes de reaccionar.** Las ventas llegan al 41 % de la meta en todas las regiones y casi en todos los meses; una brecha tan pareja es característica de una meta mal escalada (por ejemplo, definida sobre otra base o sobre otro periodo), no de un fallo comercial regional. Hasta validarlo, no se recomienda tomar decisiones de personal o de incentivos con este indicador.

2. **Investigar las devoluciones de Tecnología.** Es la categoría con 6,10 % frente a 4,15 % global. El motivo se reparte entre *Defecto* y *Cambio* (84 y 90 unidades en total), así que conviene cruzar la categoría con el motivo y con el proveedor antes de actuar.
3. **Mantener los tres canales** y buscar crecimiento por segmento o categoría, ya que el canal no discrimina.

6.3. Limitaciones

- **Datos sintéticos** con incidencias intencionales: las cifras ilustran el método, no el desempeño de una empresa real.
- **Seis meses** (enero a junio de 2026): no hay estacionalidad ni comparación interanual.
- **Sin costos**: se mide ingreso, no margen; una categoría con muchas devoluciones puede ser más o menos rentable que lo que sugieren sus ingresos.
- **Decisiones de limpieza.** Se rechazaron 7 registros (0,58 % de las filas) y se imputaron 2 precios. Ninguna decisión mueve el total más de 0,24 %; aun así, las 5 reglas con rechazo deben confirmarse con el dueño del dato.
- **Devoluciones sin fecha**: la tasa se asigna al periodo de la venta original y no se puede analizar la demora entre venta y devolución.
- **No se validó en Power BI**: los guiones M son equivalentes al pipeline en Python y se escribieron con cuidado, pero no se ejecutaron.
- **Recuperación de precio**: la regla R6 supone que las ventas se facturan a precio de lista; se verificó en 1 198 de 1 198 casos, pero podría dejar de cumplirse con datos reales.

7. Reproducir el trabajo

```
python3 pipeline/limpieza.py # limpia y crea salida/novaretail.db
uv run --no-project --with matplotlib python pipeline/graficos.py # figuras + resultados.json
sqlite3 -header -column salida/novaretail.db < sql/20_consultas.sql
make informe presentacion # PDF con la plantilla UD (tectonic)
```

Tabla 11: Estructura de la entrega.

Ruta	Contenido
`pipeline/`	Limpieza (`limpieza.py`) y figuras (`graficos.py`)
`power_query/`	Consultas M equivalentes (no ejecutadas en Power BI)
`sql/`	Esquema, estrella, cinco consultas y consultas de calidad
`salida/`	Datos limpios, auditoría, bitácora, base SQLite, figuras, resultados
`informe/`, `presentacion/`	Fuentes LaTeX y PDF
`portal/`	Sitio web explicativo

A. Consultas SQL comentadas

```sql
-- ================================================================
-- NovaRetail 360 · Consultas SQL para BI (SQLite)
-- Base: salida/novaretail.db (ventas ya depuradas; ver bitácora de calidad)
-- Definiciones: importe_neto = cantidad * precio_unitario * (1 - descuento)
-- devoluciones NO se restan de importe_neto; se reportan aparte
-- ================================================================

-- Q1 · Ventas netas por región y mes ---------------------------------
-- JOIN a clientes aporta la región. Granularidad del resultado: mes x región (igual que metas).
SELECT substr(v.fecha,1,7) AS periodo,
       c.region,
       COUNT(*) AS transacciones,
       SUM(v.cantidad) AS unidades,
       ROUND(SUM(v.importe_neto),0) AS ventas_netas
FROM ventas v
JOIN clientes c ON c.id_cliente = v.id_cliente
GROUP BY periodo, c.region
ORDER BY periodo, c.region;

-- Q2 · Cinco productos con mayores ingresos --------------------------
-- Se agrupa por la clave (id_producto), no por el nombre; el nombre solo se muestra.
SELECT p.id_producto, p.nombre_producto, p.categoria,
       SUM(v.cantidad) AS unidades,
       ROUND(SUM(v.importe_neto),0) AS ingresos_netos
FROM ventas v
JOIN productos p ON p.id_producto = v.id_producto
GROUP BY p.id_producto
ORDER BY ingresos_netos DESC
LIMIT 5;

-- Q3 · Participación por canal ---------------------------------------
-- Ventana SUM() OVER () evita una subconsulta para el total.
SELECT canal,
       ROUND(SUM(importe_neto),0) AS ventas_netas,
       ROUND(100.0 * SUM(importe_neto) / SUM(SUM(importe_neto)) OVER (),2) AS participacion_pct
FROM ventas
GROUP BY canal
ORDER BY ventas_netas DESC;

-- Q4 · Tasa de devoluciones POR UNIDADES -----------------------------
-- Dos agregaciones independientes y luego se dividen: unir devoluciones a ventas y sumar
-- cantidad repetiría las unidades vendidas de cada venta con más de una devolución.
SELECT u.unidades_vendidas,
       d.unidades_devueltas,
       ROUND(100.0 * d.unidades_devueltas / u.unidades_vendidas, 2) AS tasa_devolucion_unidades_pct,
       d.valor_devuelto,
       ROUND(100.0 * d.valor_devuelto / u.ventas_netas, 2) AS tasa_devolucion_valor_pct
FROM (SELECT SUM(cantidad) AS unidades_vendidas, SUM(importe_neto) AS ventas_netas FROM ventas) u,
     (SELECT SUM(dv.cantidad_devuelta) AS unidades_devueltas,
             ROUND(SUM(dv.cantidad_devuelta * v.precio_unitario * (1 - v.descuento)),0) AS valor_devuelto
      FROM devoluciones dv JOIN ventas v ON v.id_venta = dv.id_venta) d;

-- Q5 · Cumplimiento de metas por mes y región ------------------------
-- Las ventas se AGREGAN a mes x región ANTES de unir con metas (misma granularidad).
-- LEFT JOIN desde metas: un mes-región sin ventas aparece con 0 % en lugar de desaparecer.
WITH ventas_mes_region AS (
  SELECT substr(v.fecha,1,7) AS periodo, c.region, SUM(v.importe_neto) AS ventas_netas
  FROM ventas v JOIN clientes c ON c.id_cliente = v.id_cliente
  GROUP BY 1, 2
)
SELECT m.periodo, m.region, m.meta_ventas,
       ROUND(COALESCE(x.ventas_netas,0),0) AS ventas_netas,
       ROUND(100.0 * COALESCE(x.ventas_netas,0) / NULLIF(m.meta_ventas,0),1) AS cumplimiento_pct,
       CASE WHEN COALESCE(x.ventas_netas,0) >= m.meta_ventas THEN 'Cumple' ELSE 'No cumple' END AS estado
FROM metas m
LEFT JOIN ventas_mes_region x ON x.periodo = m.periodo AND x.region = m.region
ORDER BY m.periodo, m.region;
```